

Deep Supervised ViT with Clustering

Hidden State 모델 제안

1. 개요 및 동기

본 제안 모델은 인간의 인지적 카테고리화 능력과 재귀적 사고 과정을 AI 모델에 통합하여, 이미지 분할(Image Segmentation)과 같은 복잡한 인지 작업에서 범용적이면서 정제된 추론 능력을 확보하는 것을 목표로 합니다.

핵심 아이디어:

- 인식론적 분류 계층 (**Soft K-Means**): 모델은 최종 출력 라벨을 예측하기 전에, 잠재적 은닉 상태(Hidden State) 내에서 미분 가능한 **Soft K-Means** 클러스터링을 수행하여 물체의 윤곽선, 색상 군집 등 ***무엇을 무엇과 다르게 볼지***에 대한 인식론적 카테고리화(Epistemological Categorization)를 학습합니다.
- 재귀적 정제 (**TRM \$T\$ 루프**): **Soft K-Means**를 통해 정제된 잠재적 표상을 원본 이미지 공간으로 되돌려 원본 이미지와 결합함으로써, 모델은 자신의 초기 사고 과정을 정제하고 최종 정답의 정확도를 향상시킵니다.

2. 모델 구조: Deep Supervised ViT with Clustering Hidden State (DSC-ViT)

DSC-ViT는 사전 학습된 Vision Transformer (ViT) 기반의 인코더와 Deep Supervision 메커니즘을 기반으로 합니다.

2.1. 입력 및 잠재 상태 생성 (Initialization)

- 입력 (x): 원본 이미지 (Image, $H \times W \times C$).
- ViT 인코더: 사전 학습된 ViT 인코더 블록을 사용합니다. (예: ViT-B/16).
- 잠재 공간 투영 함수 ($\text{Projection}_{\text{D}}$):
 - 결합된 시각적 입력을 ViT 인코더가 요구하는 잠재 특징 공간(D)으로 투영하는 레이어입니다.
 - 이는 ViT의 **Patch Embedding Layer**와 동일한 역할을 수행합니다.
- 시각 공간 투영 함수 ($\text{Projection}_{\text{Visual}}$):
 - 클러스터링된 잠재 상태($z_{\text{clustered}}^{(t)}$)를 원본 이미지 채널(C)의 시각적 공간으로 되돌리는 레이어입니다. (예: 1×1 Conv, $D \rightarrow C$ 채널 수 조정)

2.2. 핵심 구성 요소: Soft K-Means Layer (인식론적 분류)

재귀 과정의 각 단계 t 에서, 모델은 현재의 잠재적 은닉 상태 $z^{(t)}$ 를 기반으로 인식론적 분류를 수행하며, 이 과정은 미분 가능합니다.

- Soft K-Means** 수행 및 클러스터 임베딩 생성:
 - $H \times W \times D$ 크기의 잠재적 표상 $z^{(t)}$ 와 K 개의 학습 가능한 중심점

$\mu^{(t)}$ 를 사용하여 Soft Assignment 확률 $q^{(t)}$ 를 계산합니다.

- $q^{(t)}$ 를 이용한 가중 평균을 통해 $H \times W \times D$ 크기의 클러스터링된 잠재적 표상($z_{\text{clustered}}^{(t)}$)을 생성합니다.

$$z_{\text{clustered}}^{(t)} = \sum_{k=1}^K q_{i,j,k}^{(t)} \cdot \mu_k^{(t)}$$

- K 는 이미지의 정답 라벨 개수와 동일하게 고정되며, $\mu^{(t)}$ 는 재귀 단계마다 학습됩니다.

2.3. 재귀적 개선 루프 (TRM-Style Recursive Refinement Loop)

모델은 TRM과 마찬가지로 T 번의 재귀적 개선 단계를 거치며, 시각적 루프를 통해 다음 입력을 생성합니다.

- 시각적 투영 루프 (Visual Projection Loop) - TRM 원본 이미지 결합 방식 준수:
 1. 클러스터링 잠재 상태를 시각적 공간에 사영:
$$z_{\text{visual}}^{(t)} = \text{Projection}_{\text{Visual}}(z_{\text{clustered}}^{(t)}) \quad (D \rightarrow C \text{ 채널 변환})$$
 2. 시각적 특징과 원본 이미지 결합:
$$x_{\text{combined}} = \text{Original Image} \times x + z_{\text{visual}}^{(t)} \quad (H \times W \times C)$$
 3. 결합된 시각 입력을 ViT 잠재 공간에 재투영:
$$\text{Input } x'^{(t+1)} = \text{Projection}_{\text{D}}(x_{\text{combined}}) \quad (C \rightarrow D \text{ 채널 변환})$$
- 재귀 통과: 결합된 입력 텐서 $x'^{(t+1)}$ 는 동일한 ViT 인코더를 통과하여 새로운 잠재적 은닉 상태 $z^{(t+1)}$ 를 생성합니다.

2.4. 최종 출력 및 Deep Supervision (Loss Function 설계)

DSC-ViT는 TRM의 구조를 단순화하여 최종 출력에 단순 세그멘테이션 헤드를 사용합니다.

1. 단순 세그멘테이션 헤드 (Simple Head):
 - 최종 은닉 상태 $z^{(T)}$ 는 단순한 MLP 또는 1×1 Conv 헤드를 통해 최종 예측 y_{pred} 를 출력합니다. (픽셀 단위 클래스 확률 맵).
2. 총 손실 (L_{total}):
 - 총 손실은 주 손실(L_{CE})과 모든 재귀 단계의 보조 손실(L_{CAT})의 합으로 구성되며, T 번의 Backpropagation을 통해 모든 가중치를 업데이트합니다.

$$L_{\text{total}} = L_{\text{CE}} + \lambda \sum_{t=1}^T L_{\text{CAT}}^{(t)}$$

3. 기존 Tiny Recursive Model (TRM)과의 차별점 및 기대 효과

| 요 소 | TRM (논문 2510.04871v1) | DSC-ViT (본 제안 모델) |

| 핵심 아이디어 | 재귀적 개선 (Recursive Refinement) | 인식론적 분류 + 시각적 루프를 통한 재귀적 사고 |

| 재귀 입력 | $\text{Input}_{\text{D}} = \text{Feature}_{\text{D}} + \text{Latent}_{\text{D}}$ | $\text{Input}_{\text{D}} = \text{Projection}_{\text{D}}(\text{Feature}_{\text{Visual}} + \text{Projection}_{\text{Visual}}(\text{Latent}_{\text{D}}))$ |

| 잠재 상태 정제 | 일반적인 **Transformer** 연산 | **Soft K-Means** (미분 가능한 카테고리화) |
| 기대 효과 | 복잡한 추론 문제에 대한 성능 증진 | 데이터를 분리하는 인지적 능력 학습 및 성능 증진 |